Оптимизация агентных способностей Qwen 2.5 с помощью GRPO в среде ToolEnv

1. Постановка задачи

Цель проекта — обучить компактную языковую модель выступать в роли интерактивного агента (Пендольфа), способного использовать внешние инструменты для решения текстовых квестов.

Агент взаимодействует со средой `PendolfEnv`, получая запросы пользователя и состояние инвентаря. Для успешного прохождения эпизода модель обязана:

1. Выстраивать цепочку рассуждений (Chain-of-Thought).
2. Вызывать инструменты в строгом формате `Action: tool_name('arg')`.
3. Соблюдать логику: проверять статус квеста (`check_quest_status`), проверять наличие предмета (`check_inventory`) и только затем взаимодействовать с ним (`take_item`).

Оценка успешности вычисляется кастомным верификатором (`PendolfVerifier`), который начисляет промежуточные награды за валидные вызовы тулов и штрафует за галлюцинации сущностей, ошибки форматирования и излишнюю болтливость.

2. Проводимые эксперименты

Для адаптации базовой LLM под строгие рамки агентной среды был применен метод Group Relative Policy Optimization (GRPO). В качестве базовой модели использовалась `unsloth/Qwen2.5-1.5B-Instruct`

Оценка проводилась на трех отложенных датасетах разного уровня сложности (`eval_easy`, `eval_medium`, `eval_hard`). На высоких уровнях сложности среда генерирует условия, требующие от агента многошагового планирования (вызов от 3 до 4 инструментов подряд).

Шаг	Название эксперимента	Описание процесса
Шаг 1	Baseline оценка	Замеряем `success_rate` и длину траектории (шаги/тулы) на базовой модели без дообучения. Модель получает только системный промпт с правилами.
Шаг 2	Обучение GRPO	Обучаем модель с использованием алгоритма GRPO. В качестве функции вознаграждения выступает `PendolfVerifier`, возвращающий скалярный `total_reward` на основе исхода эпизода и штрафов (shaping).
Шаг 3	Поведенческий анализ	Оценка обученного чекпоинта на валидационной выборке для сравнения способностей к использованию инструментов по сравнению с бейзлайном.

3. Результаты

Эксперимент продемонстрировал, что алгоритм GRPO успешно обучает модель синтаксису среды и использованию инструментов, однако жесткие рамки верификатора могут привести к зацикливанию агента (Tool-calling loop), если он не находит паттерн финального ответа.

Сводная таблица результатов (Baseline vs GRPO):

Метрика	Baseline (Easy)	Baseline (Hard)	GRPO (Easy)	GRPO (Hard)
Success Rate (Доля успешно решенных квестов)	0.0%	0.0%	0.0%	0.0%
Avg Reward (Средняя итоговая награда)	-1.11	-1.11	**+0.45**	**+0.45**
Avg Steps (Длина траектории до завершения)	1.0	1.0	**10.0**	**10.0**
Avg Tool Calls (Количество вызванных инструментов)	0.0	0.0	**5.0**	**5.0**

Ключевые выводы:

- **Полный отказ Baseline:** Необученная базовая модель Qwen 2.5 оказалась неспособна действовать в рамках среды. Модель игнорировала синтаксис `Action:`, предпочитая отвечать в формате обычного диалогового ассистента. Это приводило к мгновенному прерыванию эпизодов на первом же шаге (Avg Steps = 1.0) и стабильным отрицательным наградам (-1.11).
- **Усвоение синтаксиса через RL:** Алгоритм GRPO успешно преодолел "диалоговую" природу модели. Обученный агент научился безошибочно генерировать валидные конструкции вызова тулов (Avg Policy Violations = 0.0, Avg Invalid Actions = 0.0). Это позволило вывести среднюю награду в устойчивую положительную зону (+0.45 за счет микро-наград среды).
- **Зацикливание агента (Tool-calling loop):** Анализ траекторий выявил классическую проблему RL — зацикливание (Looping). Агент усвоил, что вызов инструментов (`check_inventory`, `take_item`) приносит промежуточные очки, но не смог выучить триггер для успешного завершения эпизода (генерацию победной реплики и флага `done=True`).
- **Итог:** В попытках максимизировать награду модель начала циклично вызывать по 5 инструментов за эпизод, пока не упиралась в жесткий лимит верификатора (Max Steps = 10). В результате эпизод принудительно прерывался со статусом `success_rate = 0.0`. Для решения этой проблемы требуется внедрение более строгого штрафа за длину траектории (Step Penalty) или добавление few-shot примеров успешного завершения квеста в системный промпт.

4. Визуализации

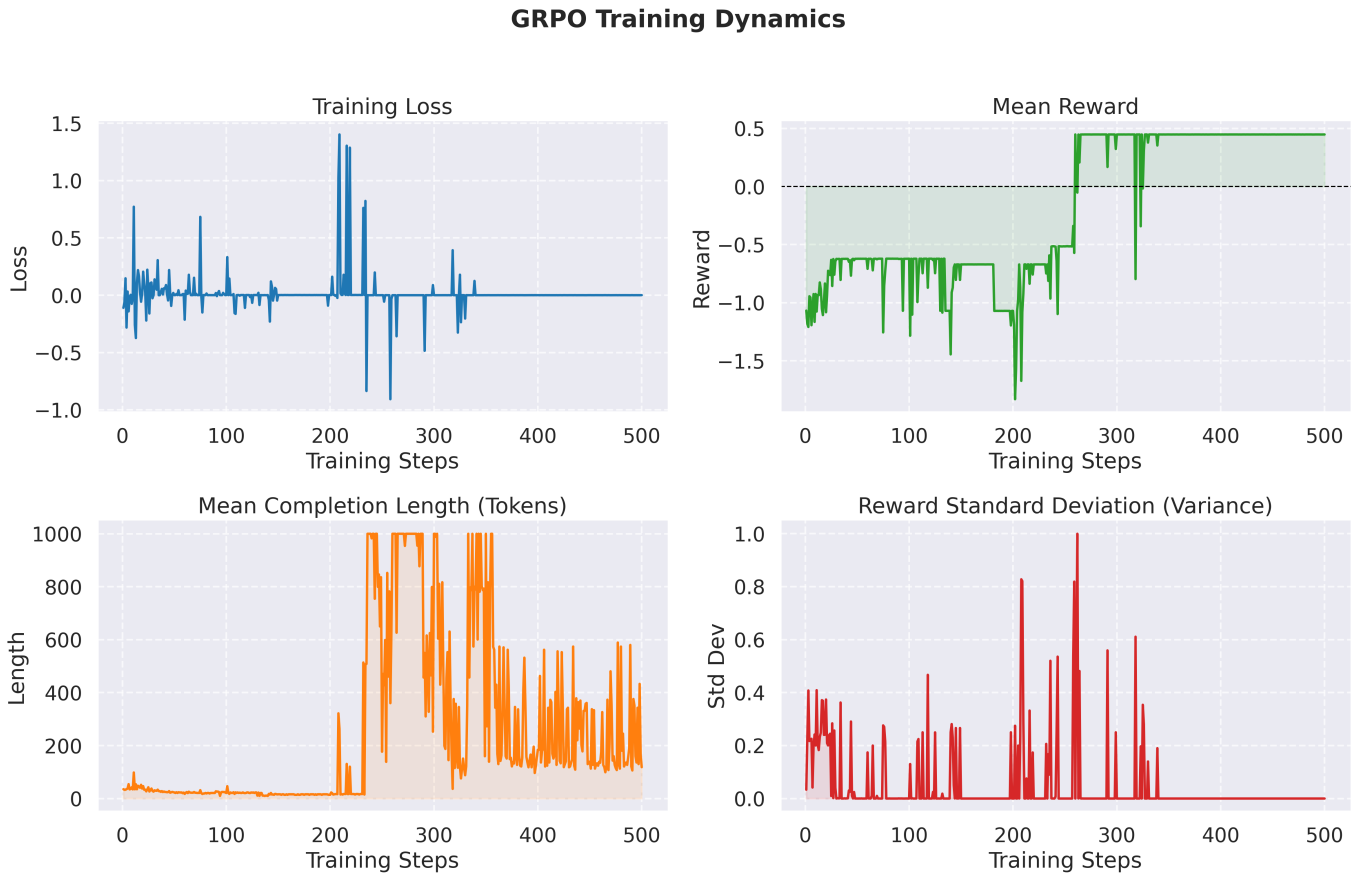

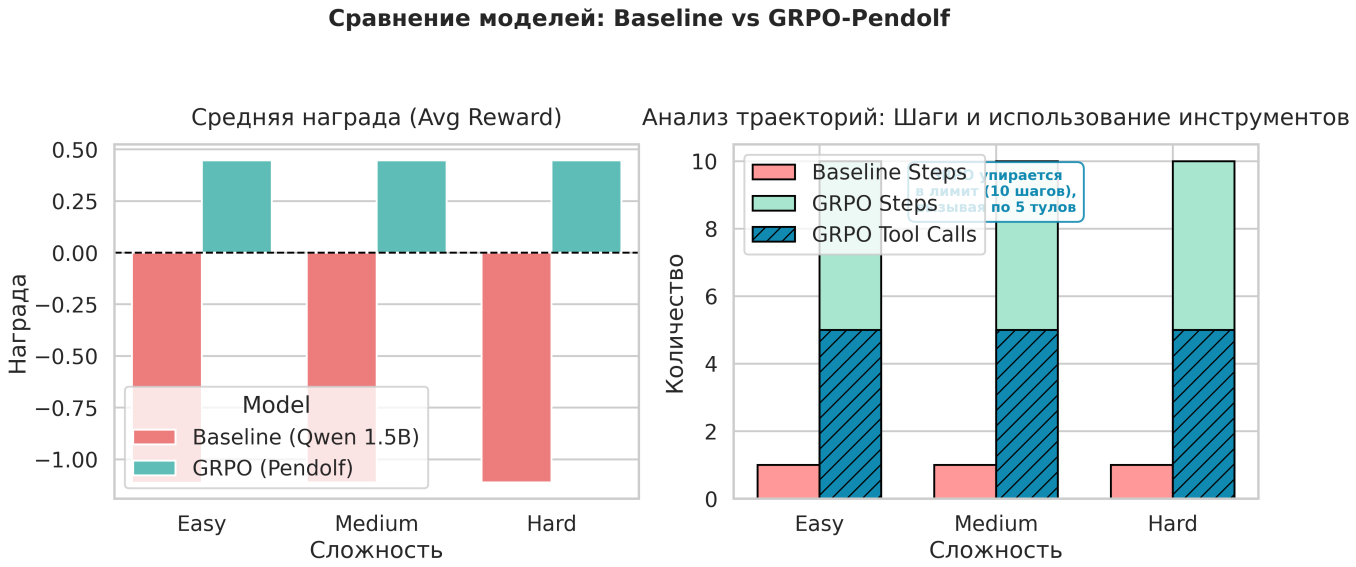

5 Система штрафов при обучении агента

Категория	Триггер / Действие	Значение	Примечание
Финальный исход (Outcome)	Успешное прохождение	**+1.0**	Выдана финальная фраза ("монеты"/"лжец"), `done=True`, награда среды > 0
	Провал / Зацикливание	**-1.0**	Лимит шагов превышен ИЛИ финальное действие неверное
Инструменты (Среда)	`take_item('...')`	**+0.5**	Валидный вызов инструмента взятия предмета
	`check_inventory` / `check_quest_status`	**+0.1**	Валидный вызов инструмента проверки
	Неизвестный инструмент	**-0.5**	Формат верный, но такого тула нет в среде
	Ошибка синтаксиса тула	**-0.1**	Не пройдена проверка регулярным выражением
Поощрения (Крошки)	Использование слова `Мысль:`	**+0.05**	Защита от фарма: только на 1-м и 2-м шагах (`steps < 3`)
	Наличие слова `Action:`	**+0.05**	Защита от фарма: только на 1-м и 2-м шагах (`steps < 3`)
Штрафы за поведение (Shaping)	Нарушение правил (Policy Violation)	**-0.5**	Галлюцинация сущности ИЛИ взятие предмета без проверки
	Невалидный синтаксис (Invalid Action)	**-0.3**	Суммируется за каждую кривую попытку вызова инструмента
	Зацикливание (Loops)	**-0.3**	Действие полностью совпадает с предыдущим шагом
	Штраф за длину сессии (Steps)	**-0.1**	За каждый совершенный шаг (стимулирует решать квест быстрее)
	Налог на инструменты (Tool Calls)	**-0.02**	За каждый вызов инструмента
	Штраф за многословие	**-0.0001 × N**	За каждый символ в тексте (без Action). N — длина строки